Данные как основа ИИ · семестр 2

Очистка без потери смысла

От диагностической таблицы к протоколу решений

Кейс «Умный кампус» · университетские пространства

Сразу нельзя ответить

- CO_2 = 0 ppm — прибор ничего не измерил или записал ноль?
- CO_2 = 4200 ppm — ошибка выгрузки или серьёзный сигнал?
- Обе строки требуют проверки; действия могут быть противоположными.

Вопрос аудитории

Какое значение удалить прямо сейчас?

Чему научимся

- Определять единицу наблюдения и технический дубль.
- Исправлять значения по доказанным правилам.
- Сохранять нетипичные, но потенциально реальные события.
- Проверять, как очистка повлияла на массив.

Одно наблюдение — один факт

- Датчик SN-101, аудитория А-101, 16 марта, 10:00: 810 ppm.
- Тот же датчик, 10:30: 810 ppm.
- Одинаковые значения не означают одну и ту же физическую запись.

Вопрос аудитории

Какие поля позволяют установить тождество измерения?

Типы нарушений

- Формат: 21,4 и 21.4; разные формы даты.
- Структура: повтор ID, неизвестное помещение, конфликтные версии.
- Смысл: отрицательная численность, нереалистичный нуль.
- Неопределённость: экстремально высокий, но возможный CO_2.

Четыре доступных действия

- Исправить по явному правилу и перепроверить.
- Сохранить с пометкой качества.
- Исключить конкретное значение из конкретного расчёта.
- Отложить строку/поле до уточнения первоисточника.

Вопрос аудитории

Что будет, если для всех случаев выбрать удаление?

Пропуск не равен нулю

- Нет измерения — не значит «измерено 0».
- Среднее значение не восстанавливает потерянный факт.
- Сохраните признак отсутствия измерения.
- Проверьте, не сосредоточены ли пропуски в одном помещении.

Два вида повторов

- Полная копия строки с подтверждённой повторной выгрузкой — технический дубль.
- Одинаковый ID, но разные значения — конфликт, а не дубль.
- Разные времена при одинаковом CO_2 — два физических наблюдения.

Вопрос аудитории

Можно ли везде использовать drop_duplicates по CO_2?

Экстремум — не ошибка по определению

- Случай 4200 ppm требует флага и проверки.
- Если убрать высокие значения, можно скрыть аварийный режим.
- Порог исключения — предметное правило, а не желание улучшить график.

Справочник помещений

- A-101 и a 101 допустимо связать по документированному алиасу.
- Неизвестное D-999 не присваивается ближайшей комнате.
- После JOIN со справочником число наблюдений не должно незаметно вырасти или уменьшиться.

Вопрос аудитории

Почему внутреннее соединение опасно для необработанных ключей?

Сначала протокол, потом операция

- Сохранить исходник и исходные числа строк/пропусков.
- Описать правило и причину его применения.
- Применить правило в копии данных.
- Сверить баланс строк, ключи и изменённые поля.

ИИ предлагает. Проверка решает

- ИИ может написать формулу и перечень типичных проблем.
- ИИ не знает, почему датчик показал 4200 ppm.
- Перед применением правил проверьте контрпример.
- Никаких необратимых действий без решения человека.

Вопрос аудитории

Что в ответе ИИ является гипотезой, а не фактом?

Разберите плохой план ИИ

- «Удалить все пропуски».
- «Дубликат — любые строки с равным CO_2».
- «Высокие значения CO_2 удалить как выбросы».
- «Неизвестные помещения заменить ближайшими».

Вопрос аудитории

Для каждого пункта назовите риск и контроль.

Лабораторная: протокол исправлений

- Исходные файлы: поток измерений + справочник аудиторий.
- Результат: таблица, журнал решений, карантин и баланс.
- Нужно показать не менее шести спорных случаев и аудит ИИ.
- Работать можно в таблицах, Python или исследовательском маршруте.

Проверка качества сдачи

- Единица наблюдения определена.
- Каждое изменение объяснено и воспроизводимо.
- Необработанные случаи видны, а не исчезли.
- ИИ-предложения проверены по данным.

Выходной билет

- Назовите один случай, который нельзя было исправить автоматически.
- Скажите, какая проверка доказала улучшение качества данных.
- Объясните, почему «пустых ячеек не осталось» не равно «данным можно доверять».