Данные как основа ИИ · семестр 2

Одни данные — разные признаки

Почему представление зависит от вопроса

Кейс «Умный кампус» · университетские пространства

Одна таблица, два заказчика

- Управляющий хочет понятный отчёт по аудиториям.
- Инженер хочет сравнивать похожие состояния помещений.
- Одна и та же исходная запись может иметь разные полезные представления.

Вопрос аудитории

Должны ли выходные столбцы быть одинаковыми?

Данные и смысловые типы

- record_id — идентификатор, не количество.
- room_type — номинальная категория.
- co2_ppm — непрерывное измерение с единицами.
- observed_at — время, из которого получаются календарные признаки.

Сравнивать занятость корректно

- 18 человек из 20 мест: доля заполнения 0,9.
- 18 человек из 60 мест: доля заполнения 0,3.
- Смысловой признак важнее произвольного числового кода комнаты.

Вопрос аудитории

Что делать, если вместимость отсутствует?

Признак должен знать свою формулу

- day = календарная дата измерения.
- hour = час измерения.
- occupancy_ratio = people_count / capacity.
- quality_flag сохраняет ограничения исходного наблюдения.

Порог — не закон природы

- Отчёт может использовать учебный индикатор «значение выше X».
- X должен быть указан и обоснован.
- Учебные пороги не заменяют действующие санитарные нормы и калибровку.

Номинальная категория не является шкалой

- Лекционная=1, семинарская=2, лабораторная=3 — произвольные коды.
- Алгоритм расстояния увидит несуществующий порядок.
- Для номинальных категорий подойдёт индикаторное представление.

Вопрос аудитории

Почему лабораторная «дальше» от лекционной на один шаг?

Когда масштаб мешает

- Вектор содержит CO_2 около 900, температуру 22 и заполнение 0,7.
- В прямом расстоянии вклад CO_2 может доминировать.
- При масштабировании надо сохранить смысл и зафиксировать параметры.

Min–max без магии

- Формула: новое = (x−min) / (max−min).
- На новой партии не нужно пересчитывать min и max заново, если требуются сопоставимые значения.
- Результат за пределами 0–1 возможен для нового экстремума.

Стандартизация и выбросы

- Z-оценка — отклонение от среднего в единицах стандартного отклонения.
- Экстремальные наблюдения влияют на среднее и разброс.
- Масштабирование ID и произвольных категорий не придаёт им смысла.

Представление A: читаемый отчёт

- room_id, корпус, дата, час, CO_2 ppm, °C, заполнение.
- Видны статусы качества и пропуски.
- Названия категорий сохраняются для человека.

Представление Б: численная схема

- Численные поля согласованы по шкале.
- Номинальные категории закодированы без ложного порядка.
- ID остаётся для идентификации, но не участвует в расстоянии.

Из сообщения — в структурированный признак

- «В аудитории душно» -> тема «воздух».
- «Датчик не отвечает» -> тема «датчик» или нужна проверка.
- LLM предлагает метку, проверка идёт по закрытому словарю и ID.

Вопрос аудитории

Как проверить, что модель не потеряла ни одного сообщения?

Что нельзя принимать от ИИ

- «Нормализуем номер аудитории как число».
- «Всем категориям присвоим 1–2–3».
- «Всё выше 1.0 по заполнению обрежем».
- «На каждом файле пересчитаем новую шкалу».

Вопрос аудитории

Выберите самый опасный пункт для нашей задачи и объясните.

Лабораторная: две версии

- Результаты А и Б строятся из одной исходной таблицы.
- Словарь признаков: смысл, формула, единицы, ограничения.
- Пять контрольных строк + аудит рекомендаций ИИ.
- Необязательное углубление — LLM-разметка сообщений.

Работоспособность новой партии

- Сохранили ли мы правила и параметры?
- Сохранились ли ID и число наблюдений?
- Как вести себя при неизвестной категории или пустой вместимости?

Выходной билет

- Назовите преобразование, которое полезно для отчёта, но не нужно для сравнения.
- Назовите операцию, способную создать ложное числовое расстояние.
- Что вы должны проверить, прежде чем доверять признаку, извлечённому LLM?